

精读笔记

快速总结

KGAT 将知识图谱嵌入与图注意力网络相结合，通过知识感知注意力机制在协同知识图谱中传播和聚合高阶邻居信息，从而学习更准确、更具可解释性的用户和物品表示用于推荐

核心贡献

1. 提出 KGAT (Knowledge Graph Attention Network) 框架，将知识图谱中的高阶连接关系显式建模到推荐过程，实现端到端的知识感知推荐
2. 设计知识感知注意力 (Knowledge-aware Attention) 机制，在信息传播过程中根据实体与关系的语义相关性动态分配邻居权重，减少噪声传播
3. 提出注意力嵌入传播层 (Attentive Embedding Propagation Layer)，通过多层图传播有效捕获用户、物品与知识实体之间的高阶协同信号
4. 利用高注意力知识路径构建推荐解释，实现推荐结果的可解释性，并展示了知识图谱路径在用户偏好推断中的作用
5. 在 Amazon-Book、Last-FM 和 Yelp2018 三个真实数据集上取得优于 FM、NFM、CFKG、CKE、RippleNet 和 MCRec 等方法的推荐性能

研究背景

在进行推荐时，不仅要考虑用户-物品交互的主信息，也要将交互数据以外的侧信息纳入考量。

如用户的年龄、职业、兴趣标签，商品的名称、类别、视频等。

现有方法

名称	解释	缺陷	参考文献
协同过滤 (Collaborative Filtering, CF)	根据用户历史交互行为挖掘用户与物品之间的协同信号，通过相似用户或相似物品进行推荐。典型方法包括矩阵分解 (MF) 等	严重依赖用户-物品交互数据，难以利用物品内容、知识图谱等辅助信息，在数据稀疏和冷启动场景下表现受限	[12, 13, 32]
因子分解机 (Factorization Machine, FM)	通过为每个特征学习一个低维隐向量，并利用隐向量内积来建模特征的交互关系，从而有效处理高维稀疏数据	仅建模单个样本内部的特征交互，无法利用用户、物品之间的高阶关联关系和图结构信息，因此难以充分挖掘协同信号	[23]
神经因子分解机 (Neural Factorization Machine, NFM)	在 FM 的基础上引入神经网络，通过非线性变换学习更复杂的特征交互模式，提高模型表达能力	虽然增强了非线性建模能力，但仍主要关注样本内部特征组合，缺乏对实体关系和结构化知识的建模	[11]

名称	解释	缺陷	参考文献
Wide & Deep	结合 Wide 部分的记忆能力与 Deep 部分的泛化能力，同时学习人工特征组合和深层特征表示	依赖人工设计特征，且无法显式建模知识图谱中的实体关系与多跳语义连接	[7]
xDeepFM	在 DeepFM 基础上提出 Compressed Interaction Network (CIN)，显式学习高阶特征交互，同时结合隐式交互建模	虽然能够学习更高阶的特征组合，但交互仍局限于特征层面，缺乏对知识图谱结构和实体关联信息的利用	[18]

CF -> FM/NFM/Wide&Deep/xDeepFM：都只能建模特征交互

KGAT：利用知识图谱 -> 传播高阶关系 -> 建模结构化协同信号

协同知识图谱（Collaborative Knowledge Graph, CKG）是将用户-物品交互关系与知识图谱中的实体关系融合而形成的统一图结构，现有基于路径（path-based）和基于正则化（regularization-based）两类

名称	解释	缺陷	参考文献
基于路径（path-based）	提取携带高阶信息的路径，并将其输入预测模型	定义有效的元路径需要领域知识，费时费力	路径选择算法 [25, 33] 定义元路径 [14, 36]
基于正则化（regularization-based）	设计额外的损失项，以捕捉知识图谱的结构来对推荐模型的学习进行正则化	隐式建模高阶关系，并未直接将高阶关系引入推荐优化模型	KTUP [5] CFKG [1]

KGAT

1. 递归嵌入传播：根据节点邻居的嵌入更新其自身嵌入，通过递归方式进行嵌入传播，捕捉高阶连接性，时间复杂度 $O(n)$
2. 基于注意力的聚合机制：使用注意力机制学习传播过程中每个邻居的权重，使得级联传播中的注意力权重能够揭示高阶连接的重要性

方法论

模型结构

1. 嵌入层（Embedding Layer）：将协同知识图谱（CKG）中的每个节点映射为低维向量表示
2. 注意力嵌入传播层（Attentive Embedding Propagation Layer）：通过知识感知注意力机制聚合邻居信息，从而捕获协同知识图谱中的高阶关系
3. 预测层（Prediction Layer）：融合各传播层得到的表示并计算用户与物品的匹配分数，用于最终推荐

符号表

图定义

符号	含义
U	用户集合
I	物品集合
E	实体集合
$G_1 = \{(u, y_{ui}, i) u \in U, i \in I\}$	U-I 二分图
$G_2 = \{(h, r, t) h, t \in E, r \in R\}$	辅助信息知识图谱 (h 头实体, r 关系, t 尾实体)
$G = \{(h, r, t) h, t \in E', r \in R'\}$	协同知识图谱 CKG
$A = \{(i, e) i \in I, e \in E\}$	物品-实体对齐集合
$T = \{(h, r, t, t') (h, r, t) \in G\}$	负采样后的训练四元组集合

可学习参数

符号	含义
e_u	用户向量
e_i	物品向量
e_h	Head 向量
e_t	Tail 向量, 邻接节点表示
e_r	Relation 向量

维度均为 d

符号	含义
W_r	可学习, 关系投影矩阵
$\pi(h, r, t)$	边 (h, r, t) 的传播权重
$W_1^{(l)}$	Bi-Interaction 参数
$W_2^{(l)}$	Bi-Interaction 参数

嵌入层

考虑三元组 (h, r, t)

把实体向量投影到关系 r 对应的语义空间

$$\begin{aligned} e_h^r &= W_r e_h \\ e_t^r &= W_r e_t \\ W_r &\in R^{d \times d} \end{aligned}$$

基于 TransR 的平移假设，有

$$e_h^r + e_r \approx e_t^r$$

定义可信度评分 (plausibility score) 或能量分数 (energy score)

$$g(h, r, t) = \|e_h^r + e_r - e_t^r\|_2^2$$

三元组 (h, r, t) 越合理, $g(h, r, t)$ 越小

在训练时, (h, r, t) 是正样本, 我们希望模型不仅使正样本靠近, 也使负样本远离, 从 (h, r, t) 中随机替换 $t \rightarrow t'$, 构造负样本 (h, r, t') , 即错误的三元组

我们希望 $g(h, r, t) < g(h, r, t')$, 最小化前者, 最大化后者 (对比学习的早期形式), 定义损失函数

$$L_{KG} = \sum_{(h, r, t, t') \in T} -\ln \sigma(g(h, r, t') - g(h, r, t))$$

注意力嵌入传播层

信息传播

对于节点 h , 定义 ego-network (即所有以 h 为头实体的三元组集合)

$$N_h = \{(h, r, t) | (h, r, t) \in G\}$$

节点应当吸收邻接节点的信息, 构造邻居消息表示 (e_{N_h} : 将邻居向量加权求和后作为节点 h 接收到的信息)

$$e_{N_h} = \sum_{(h, r, t) \in N_h} \pi(h, r, t) e_t$$

与 GCN 不同的是, KGAT 并不认为所有邻居同等重要, 而是利用 **注意力机制** 学习权重 $\pi(h, r, t)$

KGAT 的本质不是利用注意力替代图卷积, 而是利用知识感知注意力 (Knowledge-aware Attention) 学习不同邻居对节点表示的贡献程度, 使高阶协同信号能够沿着更重要的知识图谱路径传播

知识感知注意力

对于三元组 (h, r, t) , 定义注意力得分 (TransR 关系空间中计算邻居的重要性, **本质是邻居节点 t 在关系 r 下与节点 h 的语义匹配程度**)

$$\pi(h, r, t) = (W_r e_t)^T \tanh(W_r e_h + e_r)$$

匹配程度越高, 注意力越大, 传播的信息越多; 反之注意力越小, 传播的信息越少

进一步地, 使用 Softmax 得到概率形式的权重 (注意区分这里的 π 是复用之前公式的)

$$\pi(h, r, t) = \frac{\exp(\pi(h, r, t))}{\sum_{(h, r', t') \in N_h} \exp(\pi(h, r', t'))}$$

归一化后满足 $\sum_{(h, r, t) \in N_h} \pi(h, r, t) = 1$, 因此 e_{N_h} **本质是邻居表示的加权平均**

信息聚合

获得邻居表示 e_{N_h} 后，使用聚合器更新节点表示，本文提供三种聚合器

1. GCN Aggregator: 直接相加。参数少，与经典 GCN 一致

$$f_{GCN} = LeakyReLU(W(e_h + e_{N_h}))$$

2. GraphSAGE Aggregator: 先拼接再映射。保留自身信息与邻居信息的独立性（其中 $\parallel$ 表示向量拼接）

$$f_{GraphSage} = LeakyReLU(W(e_h \parallel e_{N_h}))$$

3. Bi-Interaction Aggregator (KGAT 提出): 建模节点与邻居之间的兴趣一致性 (Affinity)（其中 $\odot$ 表示逐元素乘积）

$$f_{Bi-Interaction} = LeakyReLU(W_1(e_h + e_{N_h})) + LeakyReLU(W_2(e_h \odot e_{N_h}))$$

前两种只能表示信息叠加，而无法表示特征之间的交互关系

第三种当节点与邻居兴趣一致时（向量接近），逐元素乘积会产生较大的结果

高阶传播

为了捕获更远距离的协同信号，KGAT 将传播层堆叠，第 l 层表示定义为（ f 是聚合器）

$$e_h^{(l)} = f(e_h^{(l-1)}, e_{N_h}^{(l-1)})$$

其中邻居信息为

$$e_{N_h}^{(l-1)} = \sum_{(h,r,t) \in N_h} \pi(h, r, t) e_t^{(l-1)}$$

初始状态为嵌入层得到的表示

$$e_h^{(0)} = e_h$$

多层传播能够使模型发现 **两个从未直接交互过的用户可能拥有相似兴趣**

预测层

得到各层节点表示后

对于用户节点 u ，有 $e_u^{(0)} \rightarrow e_u^{(1)} \rightarrow e_u^{(2)} \rightarrow \dots \rightarrow e_u^{(L)}$

对于物品节点 i ，有 $e_i^{(0)} \rightarrow e_i^{(1)} \rightarrow e_i^{(2)} \rightarrow \dots \rightarrow e_i^{(L)}$

直观上似乎，传播层数越多，信息越丰富，因此直接使用最后一层即可，但论文指出并未如此

每层传播结果编码不同阶数的协同信息

不仅保留最终层表示，而是保留所有层表示，KGAT 采用 Layer Aggregation（Layer Aggregation 可以通过调整 L 控制传播强度）

$$\begin{aligned} e_u^* &= e_u^{(0)} \parallel \dots \parallel e_u^{(L)} \\ e_i^* &= e_i^{(0)} \parallel \dots \parallel e_i^{(L)} \end{aligned}$$

最终预测采用内积计算用户与物品的匹配分数

$$\hat{y}(u, i) = (e_u^*)^T e_i^*$$

训练

用户 u 交互过物品 i , $(u, i) \in R^+$, R^+ 代表正样本

我们需要知道用户 u 是否喜欢物品 j , $(u, j) \in R^-$, R^- 代表负样本 (随机采样的未交互物品)

假设用户更喜欢已交互物品而不是未交互物品, 即 $\hat{y}(u, i) > \hat{y}(u, j)$, 使用 BPR 损失, 定义训练集

$$O = \{(u, i, j) | (u, i) \in R^+, (u, j) \in R^-\}$$

损失函数定义为

$$L_{CF} = \sum_{(u, i, j) \in O} -\ln \sigma(\hat{y}(u, i) - \hat{y}(u, j))$$

综合前面的知识图谱损失和 L2 正则化项, 得到总损失函数

$$L_{KGAT} = L_{KG} + L_{CF} + \lambda \|\Theta\|_2^2$$

在训练上, KGAT 并没有同时更新两个损失, 而采用交替优化 (Alternating Optimization)

第一步, 优化 L_{KG} , 随机采样 (h, r, t, t') , 更新实体向量、关系向量、投影矩阵 W_r (先训练知识图谱)

第二步, 优化 L_{CF} , 随机采样 (u, i, j) , 执行前向传播计算 $\hat{y}(u, i)$, 然后反向传播更新参数

循环往复

实验

评估指标

对于测试用户 u , 将测试集中的真实正样本集合记为 T_u , 模型推荐的 Top-K 物品集合记为 R_u^K 。

Recall@K

衡量模型找回了多少真实感兴趣的物品

$$Recall@K = \frac{|R_u^K \cap T_u|}{|T_u|}$$

其中:

- 分子: Top-K 推荐中命中的真实物品数
- 分母: 测试集中的真实物品总数

作用: 衡量推荐结果的召回能力, 即“找出来多少正确答案”

NDCG@K

首先定义折损累计增益 (DCG) :

$$DCG@K = \sum_{i=1}^K \frac{rel_i}{\log_2(i+1)}$$

其中:

$$rel_i = \begin{cases} 1, & \text{第 } i \text{ 位推荐正确} \\ 0, & \text{否则} \end{cases}$$

再利用理想排序对应的 $IDCG@K$ 进行归一化：

$$NDCG@K = \frac{DCG@K}{IDCG@K}$$

作用： 衡量推荐排序质量，命中的物品排得越靠前，NDCG 越高

最终结果

对所有测试用户分别计算 Recall@K 和 NDCG@K，再取平均值：

$$Recall@K = \frac{1}{|U|} \sum_{u \in U} Recall_u@K$$

$$NDCG@K = \frac{1}{|U|} \sum_{u \in U} NDCG_u@K$$

KGAT 默认设置 $K = 20$

因此论文报告的指标为：

- Recall@20: Top-20 推荐的召回能力
- NDCG@20: Top-20 推荐的排序质量

消融实验

消融实验表明，**知识感知注意力机制** 比 **知识图谱嵌入模块** 带来的收益更显著。若对所有邻居采用均匀权重进行传播，会引入大量噪声信息，降低高阶协同信号传播质量，因此 Attention 是 KGAT 性能提升的关键因素之一

结论

KGAT 的注意力机制不仅能够提升推荐效果，还能够从协同知识图谱中挖掘用户与目标物品之间的重要高阶连接，并将这些高注意力路径作为推荐依据进行解释。例如，用户曾阅读《Old Man's War》，目标书《The Last Colony》与其拥有相同作者 John Scalzi，因此模型通过“用户 → 书籍 → 作者 → 书籍”的知识路径完成推荐。该案例表明，KGAT 兼具推荐能力与可解释性；同时也说明知识图谱中实体质量会直接影响解释质量，过于泛化的实体（如 English）可能产生低质量解释，因此作者提出未来可通过 Hard Attention 进一步过滤无效实体。